


Задача 1. №1.



$$\text{где } U = \begin{pmatrix} u_1(x) \\ u_2(x) \end{pmatrix}$$

$Id(\cdot)$ - тождественное преобразование (ф-ия)

Как видно из схемы, у нас можем 7 параметров: смещения (b_{12}, b_{11}, b_2) и веса ($w_{11}, w_{12}, w_{21}, w_{22}$).

№2.

① Начнём с производной MSE по выходам сети:

$$\frac{\partial MSE}{\partial \hat{y}(x_i)} = \frac{2}{n} \sum_{i=1}^n (\hat{y}(x_i) - y_i)$$

② Возьмём производные выходов сети по выходам посл. слоя:

$$\frac{\partial \hat{y}(x_i)}{\partial w_{2h}} = \frac{\partial}{\partial w_{2h}} \left(\sum_{h=1}^2 w_{2h} \cdot u_h(x) + b_2 \right) = u_h(x_i); \quad \frac{\partial \hat{y}(x_i)}{\partial b_2} = 1$$

Также, вычислим производные выходов сети по выходам последнего слоя: $\frac{\partial \hat{y}(x_i)}{\partial u_h(x_i)} = w_{2h}$

Теперь вычислим производные MSE по параметрам и входам последнего слоя:

$$\frac{\partial MSE}{\partial w_{2h}} = \sum_{i=1}^n \frac{\partial MSE}{\partial \hat{y}(x_i)} \cdot \frac{\partial \hat{y}(x_i)}{\partial w_{2h}}$$

$$\frac{\partial MSE}{\partial b_2} = \sum_{i=1}^n \frac{\partial MSE}{\partial \hat{y}(x_i)} \cdot \frac{\partial \hat{y}(x_i)}{\partial b_2}$$

$$\frac{\partial MSE}{\partial u_h} = \sum_{i=1}^n \frac{\partial MSE}{\partial \hat{y}(x_i)} \cdot \frac{\partial \hat{y}(x_i)}{\partial u_h}$$

③ Теперь будем разбираться с производными по параметрам первого слоя. Для начала нам понадобится производная функции активации: $\sigma'(x) = -(1 + e^{-x})^{-2} \cdot (-1) \cdot e^{-x} = (1 + e^{-x})^{-2} \cdot (1 + e^{-x} - 1) = \sigma^2(x) \cdot (\sigma^{-1}(x) - 1) = \sigma(x) \cdot (1 - \sigma(x)) \Rightarrow \boxed{\sigma'(x) = \sigma(x) \cdot (1 - \sigma(x))}$

Теперь возьмём производные выходов первого слоя по его

параметрами:

$$\frac{\partial MSE}{\partial w_{1h}} = \sum_{i=1}^n \frac{\partial U_h(X_i)}{\partial w_{1h}} = \frac{\partial}{\partial w_{1h}} \left(\sigma(w_{1h} X_i + b_{1h}) \right) = U_h(X_i) \cdot (1 - U_h(X_i)) \cdot X_i$$

$$\frac{\partial U_h(X_i)}{\partial b_{1h}} = U_h(X_i) \cdot (1 - U_h(X_i)) - \text{аналогично}$$

Наконец, вычислим производные MSE по параметрам первого слоя:

$$\frac{\partial MSE}{\partial w_{1h}} = \sum_{i=1}^n \frac{\partial MSE}{\partial U_h(X_i)} \cdot \frac{\partial U_h(X_i)}{\partial w_{1h}}$$

$$\frac{\partial MSE}{\partial b_{1h}} = \sum_{i=1}^n \frac{\partial MSE}{\partial U_h(X_i)} \cdot \frac{\partial U_h(X_i)}{\partial b_{1h}}$$

N3.

Пусть обучающая выборка выборка слоев большая. Тогда можно, например, использовать стохастический градиентный спуск. А именно,

1. Разбиваем данные на блоки (батчи)
2. Для каждого блока считаем градиент и обновляем параметры.

$$\theta_{t+1} = \theta_t - \eta \cdot \nabla L_t, \text{ где } L_t = \frac{1}{B} \cdot \sum_{b=1}^B L(\hat{y}_{\theta_t}(X_{i_b}))$$

$$\theta_{t+1} = \theta_t - \eta \cdot \nabla L, \text{ где } L = \frac{1}{B} \cdot \sum_{b=1}^B L(\hat{y}_{\theta_t}(X_{i_b}), Y_{i_b}), \text{ где } B - \text{размер блока } (X_1, \dots, X_b) - \text{текущий блок.}$$